# Analisis MAGIC Gamma Telescope dengan SVM

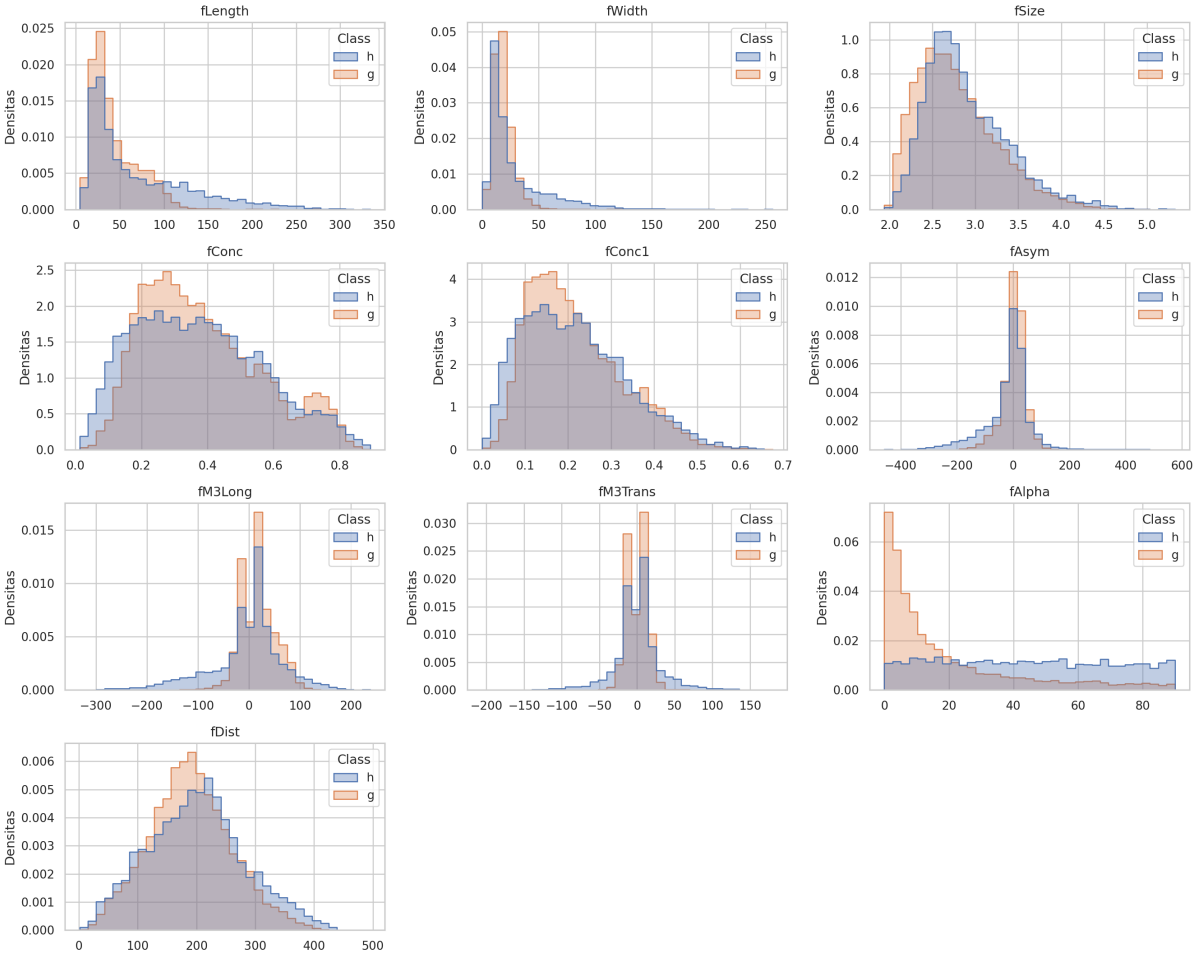
Eksplorasi Data, Standardisasi, dan Evaluasi Klasifikasi

Praneeta Bhojwani - 10324002

## 1 Gambaran Umum dan Distribusi Data

Analisis bertujuan membedakan *gamma* sebagai sinyal dan hadron sebagai latar belakang menggunakan sepuluh fitur numerik citra *air shower*. Dataset MAGIC memuat hasil simulasi Monte Carlo, bukan pengamatan teleskop langsung [1]. Target dipetakan menjadi $g = 1$ dan $h = 0$, sehingga *false positive* berarti hadron yang salah diterima sebagai gamma.

Data awal memiliki 19.020 baris: 12.332 gamma dan 6.688 hadron. Tidak ditemukan nilai hilang atau tidak finite, tetapi terdapat 115 duplikat persis, seluruhnya pada kelas hadron. Duplikat dihapus sebelum pembagian data untuk menghindari salinan identik pada latih dan uji. Tersisa 18.905 baris, dengan proporsi gamma 65,23% dan hadron 34,77%. Tanpa identitas peristiwa, penghapusan ini merupakan keputusan konservatif, bukan bukti bahwa baris tersebut berasal dari satu peristiwa fisik.

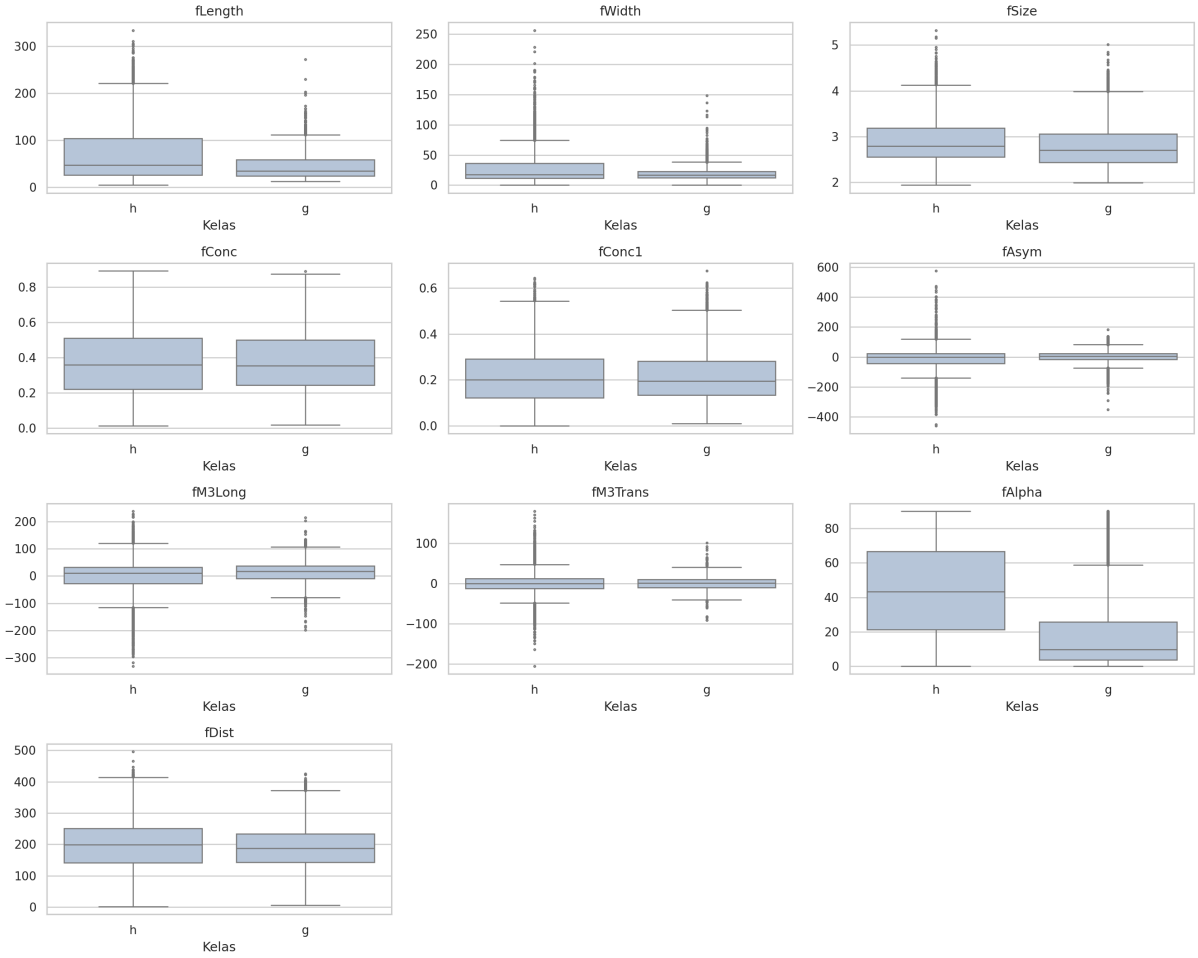



**Gambar 1:** Distribusi seluruh fitur pada 15.124 sampel latih. Densitas dinormalisasi per kelas; biru adalah hadron ($h$), oranye adalah gamma ($g$).

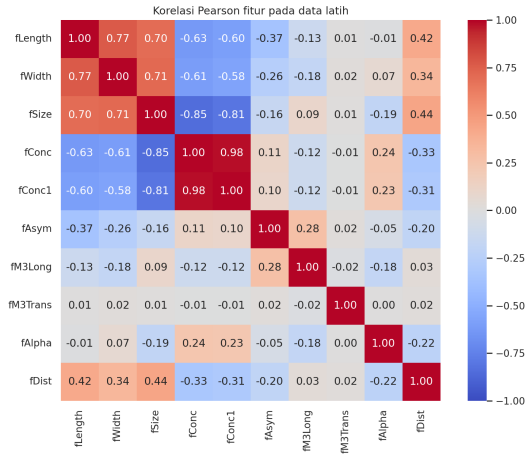
`fLength` dan `fWidth` menceng kuat ke kanan, sedangkan `fAsym` dan momen orde tiga memiliki nilai bertanda. Rentang fitur berbeda jauh; karena itu, standardisasi diterapkan sebelum SVM. `fSize` sudah berupa logaritma ukuran citra sehingga tidak langsung ditransformasi log kembali.

## 2 Perbandingan Karakteristik Antarkelas

Boxplot menunjukkan bahwa `fAlpha` gamma cenderung lebih kecil: median latihnya 9,77°, dibandingkan 43,35° pada hadron. Median `fLength` juga lebih kecil untuk gamma (34,63 versus 47,16). Namun, distribusi tetap bertumpang tindih; pemisahan kelas tidak dapat dipastikan hanya dari satu fitur.




**Gambar 2:** Median, kuartil, dan pencilan seluruh fitur menurut kelas pada data latih. Semua pencilan tetap ditampilkan.




**Gambar 3:** Korelasi Pearson antarfitur pada data latih.

Korelasi `fConc` dan `fConc1` mencapai 0,976, sedangkan `fSize` dan `fConc` berkorelasi $-0,851$. Korelasi mengindikasikan kemiripan informasi, bukan hubungan sebab-akibat atau alasan otomatis untuk membuang fitur.

Pencilan tidak dihapus hanya karena berada di luar 1,5 IQR. Nilai ekstrem dapat membawa informasi klasifikasi. Seluruh sepuluh fitur dipertahankan; belum dilakukan eksperimen seleksi fitur atau transformasi distribusi.

Semua grafik eksplorasi memakai data latih. Dengan demikian, keputusan pemodelan tidak didasarkan pada pola data uji.

# 3 Pembagian Data, Standardisasi, dan Pengembangan Model

Pembagian menggunakan `test_size=0.2`, `random_state=42`, dan `stratify=y`. Terdapat 15.124 sampel latih (9.866 gamma; 5.258 hadron) dan 3.781 sampel uji (2.466 gamma; 1.315 hadron). Bagian validasi berasal dari lima lipatan terstratifikasi di dalam data latih, sehingga tidak memerlukan set validasi terpisah.

`StandardScaler` dan SVM disatukan dalam `Pipeline`. Untuk fitur ke-$j$, $z_j = (x_j - \mu_{j,\text{latih}})/\sigma_{j,\text{latih}}$. Pada setiap fold, scaler hanya belajar dari bagian latih fold tersebut [2]. Standardisasi menyetarakan skala, tetapi tidak membuat distribusi otomatis normal atau menghapus pencilan.

`LinearSVC` memakai batas linear, *squared-hinge loss*, dan `dual=False`. SVM RBF memakai `SVC` dengan kernel $K(\mathbf{x}, \mathbf{x}') = \exp[-\gamma\|\mathbf{x} - \mathbf{x}'\|^2]$. $C$ mengatur penalti pelanggaran margin, sedangkan $\gamma$ mengatur jangkauan pengaruh titik. Karena solver dan loss juga berbeda, perbandingan ini tidak mengisolasi pengaruh kernel semata [3,4].

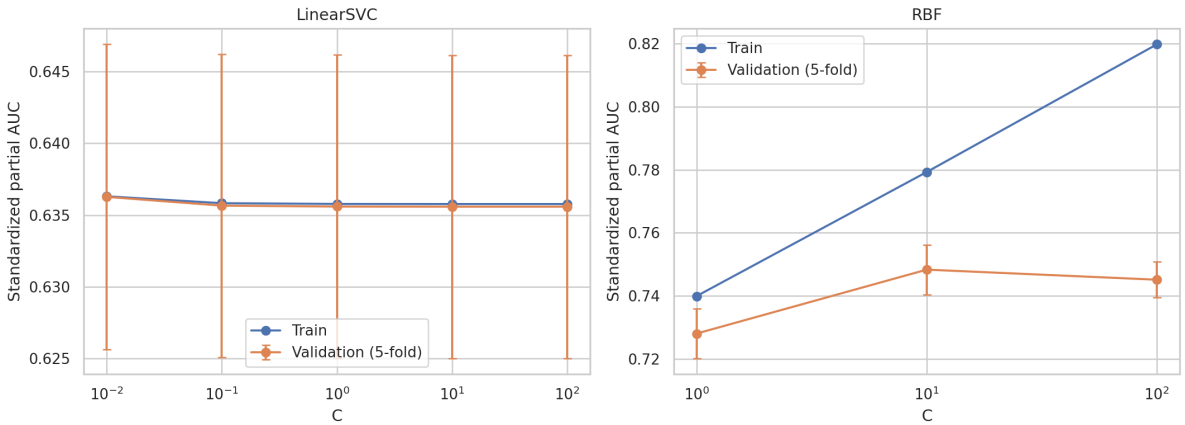
**Tabel 1:** Ruang pencarian parameter; masing-masing kandidat diuji pada lima fold.

| Model | $C$ | $\gamma$ | Bobot kelas |
|---|---|---|---|
| LinearSVC | 0,01; 0,1; 1; 10; 100 | – | None; balanced |
| RBF | 1; 10; 100 | 0,01; 0,1; 1 | None; balanced |

Sebanyak 10 kandidat linear dan 18 kandidat RBF dibandingkan berdasarkan rata-rata **standardized partial ROC AUC** (pAUC) pada FPR 0–0,10. Fokus ini mengikuti pentingnya menolak hadron [1]. pAUC bukan akurasi atau recall pada FPR 10%; acuan acak bernilai 0,5 dan sempurna 1 [5].

**Tabel 2:** Kandidat terbaik setiap model. SD menyatakan variasi antarfold, bukan interval kepercayaan.

| Model | Parameter terpilih | pAUC latih | pAUC validasi ± SD | AUC validasi |
|---|---|---|---|---|
| LinearSVC | $C = 0{,}01$; balanced | 0,6363 | $0,6363 \pm 0,0106$ | 0,8429 |
| RBF | $C = 10$, $\gamma = 0{,}1$; balanced | 0,7793 | $0,7483 \pm 0,0079$ | 0,9247 |




**Gambar 4:** Rata-rata pAUC latih dan validasi. Bobot kelas, serta $\gamma$ untuk RBF, ditahan pada nilai terbaik. Error bar adalah SD validasi.

RBF terpilih dengan $C = 10$, $\gamma = 0,1$, dan `class_weight=balanced`. pAUC validasinya 0,7483, dibandingkan 0,6363 pada LinearSVC. Gap pAUC latih–validasi RBF sekitar 0,0310, sedangkan skor linear sama-sama rendah dan hampir berimpit. Pola ini konsisten dengan keterbatasan batas linear pada data ini. Gap RBF menunjukkan sebagian kecocokan pada data latih tidak bertahan pada validasi; model tidak dinilai hanya dari skor latihnya.

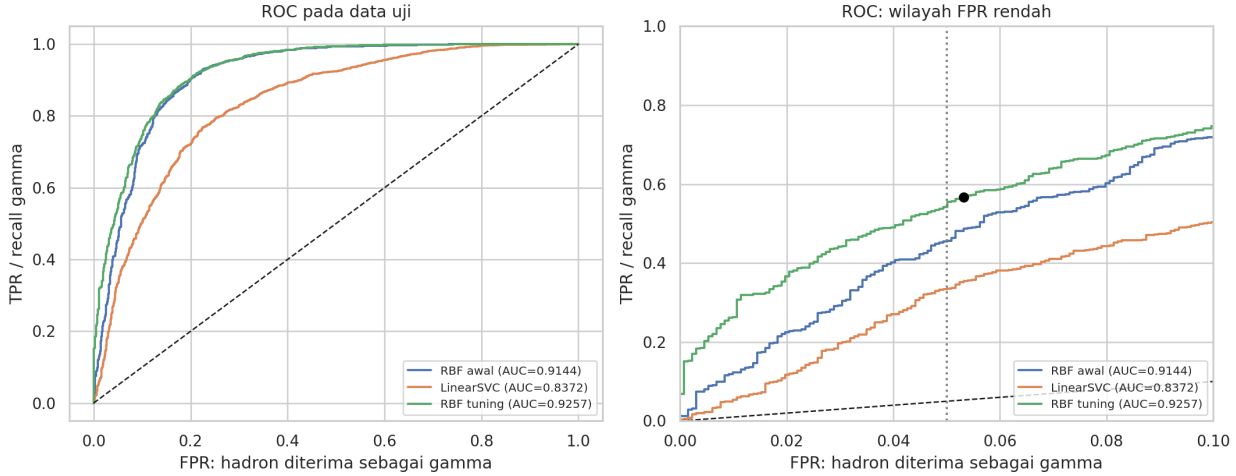
# 4 Evaluasi Model pada Data Uji

Model final dipilih dari skor CV sebelum data uji digunakan. Hasil berikut membandingkan RBF awal ($C = 1$, $\gamma =$ `scale`, bobot None), LinearSVC terbaik, dan RBF hasil tuning pada 3.781 sampel yang sama. RBF awal juga memakai standardisasi. Tebakan selalu gamma menghasilkan akurasi 65,22%, sehingga akurasi model perlu dibandingkan dengan acuan tersebut.

**Tabel 3:** Evaluasi uji dengan threshold default. BA adalah balanced accuracy; F1 adalah macro F1.

| Model | Akurasi (%) | BA (%) | F1 | ROC AUC | pAUC | FPR (%) |
|---|---|---|---|---|---|---|
| RBF awal | 87,15 | 83,47 | 0,8505 | 0,9144 | 0,6974 | 28,59 |
| LinearSVC | 78,23 | 76,48 | 0,7623 | 0,8372 | 0,6274 | 29,28 |
| RBF tuning | 86,70 | 85,08 | 0,8526 | 0,9257 | 0,7467 | 20,23 |

RBF hasil tuning memperoleh AUC 0,9257 dan pAUC 0,7467, lebih tinggi daripada RBF awal (0,9144 dan 0,6974). Akurasi justru turun dari 87,15% menjadi 86,70%, atau 0,45 poin persentase. Hal ini tidak bertentangan dengan pemilihan model, karena tuning mengoptimalkan pAUC, bukan akurasi. Balanced accuracy meningkat dari 83,47% menjadi 85,08%, sementara FPR turun dari 28,59% menjadi 20,23%.




**Gambar 5:** Kurva ROC seluruh model pada data uji dan pembesaran wilayah FPR rendah. Titik hitam memakai threshold yang ditetapkan dari prediksi OOF data latih.

**Tabel 4:** Metrik per kelas model final pada threshold default.

| Kelas | Precision | Recall | F1-score | Jumlah |
|---|---|---|---|---|
| Hadron | 0,8157 | 0,7977 | 0,8066 | 1.315 |
| Gamma | 0,8934 | 0,9039 | 0,8986 | 2.466 |

Pada threshold default, 1.049 dari 1.315 hadron dikenali dengan benar dan 266 salah diterima sebagai gamma. Sebanyak 2.229 dari 2.466 gamma dikenali, sedangkan 237 ditolak. Recall gamma mencapai 90,39%, tetapi recall hadron hanya 79,77%. Dengan demikian, akurasi 86,70% masih disertai kontaminasi latar belakang yang perlu diperhatikan.

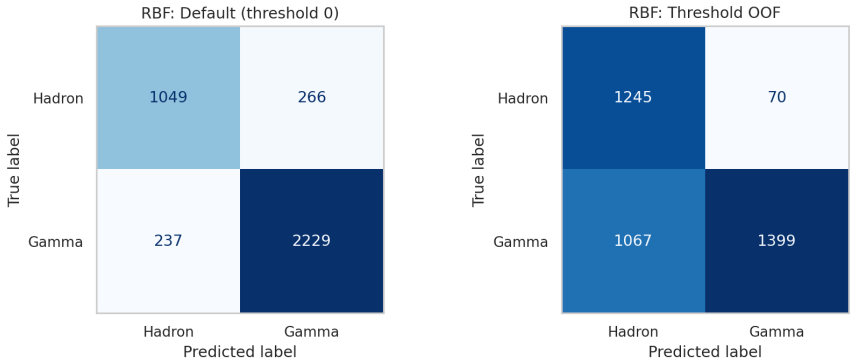
**Pengaruh standardisasi.** Pada RBF awal, pAUC validasi tanpa scaling adalah 0,6457 dan setelah `StandardScaler` menjadi 0,7108; AUC penuh masing-masing 0,8697 dan 0,9156. Perbandingan memakai fold dan aturan $\gamma =$ `scale` yang sama. Dengan sepuluh fitur terstandardisasi, aturan tersebut menghasilkan $\gamma = 0,1$. Angka ini menunjukkan hasil dua konfigurasi awal, bukan jaminan bahwa scaling selalu mengungguli semua konfigurasi tanpa scaling.

# 5 Threshold, Pembahasan, dan Kesimpulan

Threshold dipilih dari skor *out-of-fold* (OOF) data latih: setiap sampel diberi skor oleh model yang tidak melatih sampel itu. Dipilih recall gamma tertinggi dengan FPR $\leq 5\%$, target yang ditetapkan sebelum melihat test. Threshold diperoleh sebesar 1,1100, dengan FPR OOF 4,98% dan recall gamma OOF 57,39%. Skor SVM bukan probabilitas.

**Tabel 5:** Trade-off threshold model final pada data uji; gamma adalah kelas positif.

| Aturan | TN | FP | FN | TP | FPR (%) | Recall gamma (%) |
|---|---|---|---|---|---|---|
| Default (0) | 1049 | 266 | 237 | 2229 | 20,23 | 90,39 |
| Threshold OOF | 1245 | 70 | 1067 | 1399 | 5,32 | 56,73 |




**Gambar 6:** Confusion matrix model final pada threshold default dan threshold dari OOF. Baris menyatakan kelas aktual, kolom menyatakan prediksi.

Threshold OOF mengurangi hadron yang lolos dari 266 menjadi 70. FPR uji turun dari 20,23% menjadi 5,32%, tetapi recall gamma juga turun dari 90,39% menjadi 56,73%. Precision gamma meningkat dari 89,34% menjadi 95,23%, sedangkan akurasi turun menjadi 69,93%. Sampel yang diterima lebih murni pada proporsi kelas dataset ini, tetapi banyak gamma terbuang. Target FPR 5% **belum terpenuhi pada data uji**.

**Batas interpretasi.** Hyperparameter sudah dipilih dengan CV yang sama, sehingga prosedur OOF ini bukan nested CV dan masih dapat optimistis. Skala skor juga dapat berubah setelah refit. FPR OOF di bawah 5% tidak menjamin batas tersebut terpenuhi pada test atau data baru; threshold tidak disesuaikan ulang menggunakan test.

Hadron kurang terwakili dalam dataset, padahal dominan pada pengamatan nyata [1]; precision dan accuracy di sini tidak langsung berlaku untuk teleskop nyata. Hasil hanya mencakup satu pembagian train-test dan grid terbatas. Pengembangan berikutnya dapat memakai data kalibrasi threshold terpisah, validasi eksternal, serta pengujian transformasi atau seleksi fitur melalui pipeline.

**Kesimpulan.** Di antara model yang diuji, RBF dengan $C = 10$, $\gamma = 0,1$, dan bobot kelas balanced memberikan pAUC validasi tertinggi. Model mencapai AUC uji 0,9257 dan akurasi 86,70% pada threshold default. Evaluasi FPR menunjukkan bahwa penolakan hadron yang lebih ketat harus dibayar dengan kehilangan sebagian sinyal gamma.

### Sumber dan acuan

Data dan keluaran eksperimen: `magic04.data`, `magic04.names`, serta `MAGIC_Gamma_SVM.ipynb`. Seluruh gambar berasal dari notebook yang dijalankan dengan scikit-learn 1.8.0.

[1] Bock, R. (2004). *MAGIC Gamma Telescope*. UCI. `https://doi.org/10.24432/C52C8B`.

[2] scikit-learn. *Common pitfalls and recommended practices*.

[3–5] scikit-learn. Dokumentasi `LinearSVC`, `SVC`, dan `roc_auc_score`.